

Описание алгоритма

Пусть T - исходный текст. p - паттерн со знаками $?$. Пусть также d' и d'' - число $?$ в начале и конце p .

Тогда пусть $T' := T[d' : |T| - d'']$, $p := p[d' : |p| - d'']$. В таком случае верно следующее:

(1)

$$p \text{ in } T \Leftrightarrow p' \text{ in } T'$$

Пусть $P = [i_1, \dots, i_k]$ - индексы подстрок $p_1, \dots, p_k$ строки p' , в которых нет $?$. Их мы получаем линейным проходом по исходному паттерну.

С помощью алгоритма Ахо-Корасика для каждого паттерна $p_1, \dots, p_k$ найдем множество всех его вхождений:

$$M_1 = \{m_1^1, \dots, m_1^{s_1}\}$$

...

$$M_k = \{m_1^1, \dots, m_1^{s_k}\}$$

Далее будем искать такой набор вхождений этих паттернов, что из них можно сложить искомую строку. То есть будем искать такое i , что:

(2)

$$m_1^i + i_2 \in M_2$$

$$\text{and } m_1^i + i_3 \in M_3$$

...

$$\text{and } m_1^i + i_k \in M_k$$

Будем искать i следующим образом

Каждое из M_i будем хранить как множество (хэш-таблица). Будем итерироваться по множеству индексов M_1 . Для каждого из индексов m_1^i будем проверять выполнение условий, описанных выше. То есть, для каждого m_1^i мы сделаем не более $k - 1$ лукапов в хэш-таблицы.

Если мы нашли такое i , то будем говорить, что исходная строка p встречается в тексте в позиции i .

Доказательство

В данном описании содержится 2 содержательных утверждения, которые требуют доказательства:

1. $p \in T \Leftrightarrow p' \in T'$. (Имеет номер в описании (1))
2. Выполнение условий (2) даёт нам гарантию нахождения паттерна в тексте

(1) Равносильность перехода

Докажем в одну сторону:

$$p' \in T' \Rightarrow p \in T$$

Если $p' \in T'$, то $p' \in T$, т.к. $T' \subseteq T$

Так как при переходе $T' \rightarrow T$ мы добавили по краям столько же символов $?$, сколько при переходе $p' \rightarrow p$, то это значит, что вхождение p не выйдет за границы T .

В обратную сторону аналогично

(2) Корректность вхождения

Выполнение описанных условий, помеченных пунктом (2) на полях, означает, что существуют вхождения $p_1, p_2, \dots, p_k$ на таких же расстояниях, что и в исходной строке p' . Таким образом, если заменить промежуточные символы на $?$, то получится исходная строка p' . Это означает вхождение строки $p' = p_1, ? \dots ? p_2 \dots p_k$

Асимптотика

1. **Формирования списка индексов паттернов** делается линейным проходом по p . Количество паттернов k ограничено количеством символов $? + 1$.
 - Время - $O(|p|)$, память - $O(1)$
2. **Ахо-Корасик** потребует дополнительной памяти, так как нам потребуется для каждого паттерна сохранить множество всех его вхождений. Количество вхождений для каждого паттерна ограничено длиной текста, число паттернов ограничено константой.
 - Время - $O(|p| + |T|)$, память - $O(|T|)$
3. **Проверка условий** требует пройти по всем элементам в M_1 , число которых ограничено длиной текста. Далее, для каждого элемента необходимо сделать не более чем константного числа запросов в множества $M_2, \dots, M_k$
 - Время - $O(|T|)$

Итого имеем:

- Время: $O(|p| + |T|)$, память: $O(|T| + |p|)$